TrailGuard TW：預期貢獻與學術價值

整理日期：2026-11-11
本文件內容：

- 一、研究定位（缺口在哪裡）
- 二、預期貢獻（C1–C6）
- 三、學術價值（理論、方法、實務、政策）
- 四、可檢驗的研究假設（H1–H5）
- 五、A–F 加強重寫版
- 六、研究限制與效度威脅（先寫出來，審查時比較站得住）
- 參考文獻

一、研究定位：三個領域交會處的空白

研究領域	已經做到的	尚未處理的（本研究切入點）
LLM 行程規劃	TravelPlanner、ChatGPT 旅遊規劃評測（ChinaTravel）、旅遊規劃多目標評測（COMPASS）等基準顯示，LLM 在多約束規劃上的表現很差：GPT-4-Turbo 只有 0.6% [1]，GPT-4o 在 ChinaTravel 上為 0% [2]；神經符號方法則能提升到 93.9% [3]	這些基準處理的是預算、時間、偏好等「旅遊約束」，沒有處理「安全約束」，也沒有區分「錯誤但安全」與「錯誤而危險」
RAG／知識圖譜	時序 RAG（TG-RAG）[4]、知識圖譜降低幻覺 [5]、Agentic RAG [6]	多在通用問答或醫療領域驗證，很少處理「資料數天內就會失效」的戶外安全資訊（封閉、預報、許可）
山域安全與運動醫學	臺灣山域事故統計 [7][8]、玉山高山症流行病學 [9][10]、步程模型誤差 [11][12]	這些知識分散在官方 PDF、醫學期刊與社群，沒有被整合成可計算、可追溯的決策支援
人機互動／AI 信任	認知投降 [13]、模型諂媚 [14]、自動化偏誤 [15]	戶外高風險情境中的 AI 依賴，目前只有媒體案例 [16][17]，缺少系統化的評估方法

定位句： 本研究位於「LLM 規劃 × 時序知識檢索 × 山域安全」的交會處，要回答一個現有基準沒有問過的問題：當 AI 的錯誤會讓人陷入危險時，該怎麼設計和評估它？

二、預期貢獻（C1–C6）

C1　問題定義：把「行程規劃」重新定義為「帶有安全責任的風險決策」

- 現有研究把行程規劃當成最佳化問題，目標是滿足約束、追求偏好最大化。
- 本研究把它改寫成三層決策問題：
  1. 可行性：能不能走
  2. 安全餘裕：走得有多安全
  3. 可撤退性：出狀況時退不退得回來
- 計畫被視為一組「假設」：每個假設都附有失效條件（回頭時間、紅旗），而不是一個固定答案。
- 學術意義：將「安全餘裕」與「可撤退性」形式化為規劃約束。

C2　評估方法：提出「錯誤安全率（False-Safe Rate, FSR）」與真安全／假安全測試集

- 現有基準只看成功率；本研究區分以下兩種錯誤：

錯誤類型	意義	例子
錯誤而危險（false-safe）	系統說可以去，實際上應該 NO-GO	颱風警報下仍給出行程
錯誤而保守（false-alarm）	系統說不要去，實際上可以	過度否決導致可用性下降

- FSR 借自醫療分級中的「低估急迫性（undertriage）」概念：ChatGPT Health 對真正急症的低估率約 52% [18]，GPT-5.5 的危險性低估率為 0.2% [19]。本研究把這種「不對稱的錯誤成本」帶進 AI 規劃評估。
- 30 個壓力與對抗案例（資料衝突、缺少資料、誘導幻覺、使用者高估自身體能、突發封閉）可公開為測試集，供後續研究重現。
- 學術意義：提供第一批以安全為中心的代理人規劃評估指標與資料（就目前文獻回顧所見；投稿前建議再做一次系統性檢索確認）。

C3　架構：「LLM 不算數字」的神經符號分工與 Evidence Ledger

- LLM 只負責理解、追問與解釋；步程、天氣窗格、高山症風險與最佳化交給確定性的 Python 引擎計算。
- 每一個數字都必須寫入 Evidence Ledger，紀錄來源、時間戳與計算路徑（No source, no number）。
- 這個設計回應兩個已知問題：
  - LLM 的引用中有 50–90% 的內容沒有被來源完整支撐 [20]
  - LLM 的實際計算準確率最好也只有約 63% [21]
- 學術意義：讓「可解釋性」從事後說明，變成可以稽核的數據血緣（data lineage）。

C4　知識表示：會「過期」的時序知識圖譜

- 臺灣山域資訊具有強烈的時效性。例如 2026-08-07 多個國家公園全面禁止生態保護區入園，10 月下旬才陸續重開 [22]；氣象署的國家公園預報每 6 小時更新一次 [23]。
- 知識圖譜中每個事實都帶有生效時間、失效時間、觀測時間、來源可信度等時間欄位，檢索時以「出發當日仍然有效」作為硬性篩選條件。

- 學術意義：把時序 RAG 從新聞、通用問答延伸到「事實失效就有安全後果」的領域，並以消融實驗量化知識圖譜的貢獻。

C5　安全機制：不能被平均分數抵銷的硬性紅旗覆寫

- 多數風險評分會把各項風險加權平均。本研究主張：某些條件（颱風警報、步道封閉、嚴重高山症症狀）一旦成立，就直接輸出 NO-GO 或升級給人工處理，不參與加權。
- 依據：
  - 2025 年 8 月玉山東峰的雷擊案例中，天候因素直接讓直升機無法救援 [24]
  - 聖母峰的研究顯示，生還者與罹難者的登頂時間差了約 4 小時（生還者多在 09:00–09:59 登頂，罹難者多在 13:00–13:59）[25]。可見「回頭時間」是門檻型、不是連續型的風險
- 學術意義：以消融實驗（移除紅旗層）檢驗非補償式（non-compensatory）安全規則對 FSR 的影響。

C6　範式：可移植的「領域資料代理人」設計模式

把整套設計抽象成四個元件：

1. 狀態機加上缺槽追問
2. 確定性分析引擎
3. 時序知識圖譜加上 Evidence Ledger
4. 紅旗層加上人類決策

這套模式可以移植到其他「高風險、高時效、資料分散」的領域，例如潛水、溯溪、災害疏散、慢性病自我管理。學術意義：提供一個可重用的 AI Agent 安全設計模式，而不是只做出單一應用。

三、學術價值

理論層面

- 安全優先的規劃理論： 把「安全餘裕」、「可撤退性」、「計畫即假設」形式化，補足現有 LLM 規劃研究偏重效用最大化的缺口。
- 不確定性下的人機分工： 回應「AI 該明確建議，還是輔助判斷」的辯論（D3）。本研究的立場是：AI 負責計算與舉證，人類負責撤退與問責。這也符合《人工智慧基本法》的人類自主與問責原則 [26]。

方法層面

- 新指標： FSR、證據覆蓋率（EGR）、時效錯誤率，可以和既有的限制滿足率（CSR）、系統使用性量表（SUS）一起使用。
- 新測試集： 120 個案例，涵蓋 30 條路線、3 種人物誌，加上 30 個對抗案例，可重現、可擴充。
- 嚴謹的實驗設計： 4 組對照（GPT-4o zero-shot、GPT-4o 加搜尋、RAG-only、人工流程）加 3 組消融（移除知識圖譜、驗證層、紅旗層），以信賴區間與統計檢定報告，避免「展示型」原型研究常見的單一案例論證。

實務層面

- 對準真實族群： 2025 年山域遇險者中，自組隊伍占 55.85%、獨自登山占 21.46%，50–69 歲占 48.8% [7]。這些族群正是缺少領隊經驗、又最需要行前決策支援的人。
- 補上「事前」缺口： 政府資源多投入事後搜救，例如 602 面可通話地點標示 [27]、約 7.5 億元的科技搜救計畫 [28]。本研究補的是「出發之前」的決策品質。
- 處理 AI 誤導的新風險： 國際上已出現多起登山者依聊天機器人規劃行程、最後需要搜救的案例 [16][17]。本研究提供的是「有證據、有紅旗」的替代方案，而不是禁用 AI。

政策與社會層面

- 可稽核的決策紀錄： Evidence Ledger 讓每一份行前建議都能被追溯，未來可作為登山教育、隊伍行前審查與事故檢討的材料。
- 呼應國家治理方向： 《人工智慧基本法》2026-01-14 公布施行 [26]；國科會也在研擬高風險 AI 框架 [29]。本研究可作為「高風險情境 AI 透明與問責」的具體示範。

四、可檢驗的研究假設（對應實驗設計）

假設	內容	檢驗方式
H1	TrailGuard TW 的 CSR 顯著高於 GPT-4o zero-shot 與 GPT-4o 加搜尋	120 案例配對比較（McNemar 檢定）
H2	移除紅旗層後，FSR 顯著上升	消融：完整系統 vs. 移除紅旗層
H3	移除時序知識圖譜後，時效錯誤率（引用已失效的封閉或預報資訊）顯著上升	消融：在「突發封閉」對抗案例中比較
H4	個人化步程模型的 MAPE ≤ 20%，且 P90 覆蓋率 ≥ 85%	以真實 GPX 軌跡驗證
H5	在「使用者高估體能」案例中，缺槽追問能降低系統順著使用者說（諂媚）的比例	比較有無追問機制的版本

這些假設都可以被推翻（falsifiable）。即使部分假設不成立（例如時序知識圖譜的效益不顯著），結果本身也是貢獻。

五、A–F 加強重寫版

以下只重寫我認為最需要加強的地方；標示「（新增）」的是補充內容。

A. Attention Getter（加強：反差加上族群）

2019 年「開放山林」後，臺灣登山人口快速成長，風險卻沒有跟著下降。2015 至 2024 年共發生 3,450 件山域事故，其中迷路約占 37% [27]；2025 年迷路比例升到 38.61%，遇險者有 55.85% 屬於自組隊伍、21.46% 獨自登山 [7]。更值得警惕的是三座高山型國家公園：2025 年入園人次約 15.2 萬，不到 2020 年的一半，事故率卻從 2016–2019 年的 0.04–0.05% 升到 2023–2025 年的 0.08–0.09% [8]。人變少，事故率反而翻倍（新增）。這代表問題已經不只是登山人數，而是每一支隊伍在出發前所做的決策品質（新增）。

B. But（加強：從「資訊分散」推進到「AI 會讓事情更糟」）

現有工具各自處理一部分問題：一站式服務網負責許可與封閉公告、氣象署每 6 小時更新預報 [23]、社群提供路況、地圖提供步程。但沒有任何一個工具會告訴新手：「依照你們的配速和當天的雷雨窗格，這一段 13 時前沒通過就該回頭。」

（新增）2025 年 8 月，兩名山友凌晨 0:30 出發單攻玉山東峰，約 11 時遭雷擊；因雷電加冰雹，直升機無法起飛，10 人輪流背負近 9 小時才下山 [24]。

（新增）同時，越來越多登山者改問聊天機器人。美國 Grand Teton 國家公園的搜救紀錄中，使用 AI 規劃的比例從 0 升到 26% [16]；Shasta 山有隊伍依照 Gemini 的建議只準備了 8 小時的糧水，實際卻走了 16 小時 [17]。LLM 在多約束規劃上的成功率只有 0.6% [1]，使用者面對 AI 的錯誤答案時，仍有約 80% 的機率採納 [13]。真正的危險不在於 AI 會出錯，而在於它出錯時聽起來依然很可信（新增）。

C. Cure（加強：寫出「不是什麼」）

本專題提出 TrailGuard TW（山徑守護者）：一個以證據為基礎的臺灣高山行程規劃與風險決策支援代理人。（新增）它不是幫使用者決定要不要去的「自動駕駛」，而是一個把證據攤開、把風險算清楚、把回頭條件寫明白的「副駕駛」。產出的行前決策包包括：

- 三個候選行程（安全／平衡／進取）
- 逐段風險儀表板
- 撤退點與回頭時間
- 裝備與水源檢查表
- 離線緊急卡
- 每一項數字的來源與時間戳記

D. Development（加強：寫出為什麼要這樣分工）

（新增）設計原則只有一句話：讓 LLM 做它擅長的事，把它不擅長的事拿走。

- **LLM** 擅長、本系統交給 **LLM** 的： 理解語意、追問缺少的資訊、解釋結果。
- **LLM** 不擅長、本系統拿走的：
  - 精確計算：實際計算準確率最好約 63% [21]
  - 引用來源：50–90% 的引用沒有被來源完整支撐 [20]
  - 堅持立場：約 58% 的情況會順著使用者說 [14]

因此，步程（P50／P90）、天氣窗格、高山症篩檢與最佳化都交給 Python 分析引擎；知識由時序知識圖譜與混合 RAG 提供，每個事實都帶有生效與失效時間；所有數字寫入 Evidence Ledger。（新增）高山症篩檢依據的是臺灣本土資料：玉山 1,066 位登山者中，高山症盛行率為 36% [9]。最後，硬性紅旗（颱風警報、步道封閉、嚴重高山症症狀）直接覆寫所有評分，輸出 NO-GO 或升級人工。

E. Experiments（加強：明確寫出假設與門檻依據）

120 個案例（90 個核心情境，加上 30 個壓力與對抗案例），比較 4 組對照與 3 組消融（移除知識圖譜、驗證層、紅旗層）。（新增）實驗要檢驗五個假設：H1 系統優於純 LLM、H2 紅旗層能降低 FSR、H3 時序知識圖譜能降低時效錯誤、H4 步程預測的準確度、H5 追問機制能降低諂媚。

（新增）各門檻都有文獻依據：

門檻	依據
MAPE ≤ 20%	傳統步程公式在整條路線上的誤差約 13.5–15.5% [11]，常用 App 平均低估 49–69 分鐘 [12]
FSR ≤ 2%	參照醫療分級 AI 的危險低估率 [18][19]
SUS ≥ 75	約為第 73 百分位，等級 B [30]

F. Findings（加強：從成果轉向貢獻）

（新增）本研究預期提出六項貢獻：

1. 把行程規劃重新定義為帶有安全責任的風險決策
2. 提出錯誤安全率與真安全／假安全測試集
3. 「LLM 不算數字」的神經符號分工與 Evidence Ledger
4. 會過期的時序知識圖譜
5. 不能被平均分數抵銷的紅旗覆寫
6. 可移植到潛水、溯溪、災害疏散等領域的領域資料代理人範式

（新增）這套設計也符合《人工智慧基本法》的人類自主、透明可解釋與問責原則 [26]。它示範了 AI 在高風險領域的一種負責任做法：不是取代人做決定，而是讓人做出更好的決定。

關鍵詞： 高山症、風險決策、行程規劃、檢索增強生成、時序知識圖譜、錯誤安全率、可解釋人工智慧、領域資料代理人

六、研究限制與效度威脅

先在文件中寫出這些限制，口試時比較不會被問倒：

限制	說明	緩解方式
案例不等於因果	國際 AI 誤導案例是媒體報導，無法證明 AI 是事故主因 [31]	只用來說明「動機」，不用來證明「效果」
黃金標準的主觀性	「該不該 NO-GO」需要專家判斷	請 2–3 位資深領隊獨立標註，計算一致性（Cohen's κ）
資料可得性	部分事故統計只有媒體轉述（例如高山症及墜谷 15.6%）[8]	投稿前向國家公園署索取原始資料
外部效度	30 條路線無法涵蓋全部臺灣高山	依步道分級 0–6 級分層抽樣 [32]
原型不等於實地成效	實驗室評估無法直接推論出事故率下降	寫成「行前決策品質」，不宣稱「降低事故」

參考文獻

[1] Xie, J. et al. (2024). TravelPlanner. ICML. https://proceedings.mlr.press/v235/xie24j.html

[2] ChinaTravel benchmark. https://arxiv.org/html/2412.13682v5

[3] Hao, Y. et al. LLM + SMT planning framework. https://aclanthology.org/people/yilun-hao/unverified/

[4] TG-RAG: Temporal Graph RAG. https://arxiv.org/html/2510.13590

[5] RAG-KG-IL. https://arxiv.org/html/2503.13514/

[6] Agentic RAG survey. https://arxiv.org/html/2501.09136v1

[7] 內政部消防署（2026）。114 年山域事故案件概況。https://www.nfa.gov.tw/cht/index.php?act=download&ids=26115

[8] 環境資訊中心（2026-02-12）。國家公園高山事故比率攀升。https://www.e-info.org.tw/node/243031

[9] Wang, S. H. et al. (2010). Epidemiology of AMS on Jade Mountain. https://hub.tmu.edu.tw/en/publications/epidemiology-of-acute-mountain-sickness-on-jade-mountain-taiwan-a/

[10] AMS on Jade Mountain: real-world practice. https://pubmed.ncbi.nlm.nih.gov/38331638/

[11] Wood, A. et al. (2023). PLOS ONE. https://pmc.ncbi.nlm.nih.gov/articles/PMC10727444/

[12] Are Suggested Hiking Times Accurate? (2025). https://pubmed.ncbi.nlm.nih.gov/39859097/

[13] Wharton Magazine (2026). Is AI Hijacking Our Brains? https://magazine.wharton.upenn.edu/issues/fall-winter-2026/is-ai-hijacking-our-brains/

[14] SycEval. https://arxiv.org/html/2502.08177v4

[15] Automation bias（Philosophy & Technology, 2026）. https://link.springer.com/article/10.1007/s13347-026-01090-9

[16] WIRED (2026-11-01). Chatbots Are Leading Hikers Astray. https://www.wired.com/story/chatbots-are-leading-hikers-astray-with-dangerous-consequences/

[17] KMBC (2026). Mount Shasta AI-advice rescue. https://www.kmbc.com/article/california-hikers-rescued-ai-advice/73616514

[18] Nature Medicine (2026). ChatGPT Health triage. https://www.nature.com/articles/s41591-026-04297-7

[19] BMC Emergency Medicine (2026). GPT-5.5 Manchester Triage. https://link.springer.com/article/10.1186/s12873-026-01704-7

[20] Nature Communications (2025). Citation support in LLMs. https://pmc.ncbi.nlm.nih.gov/articles/PMC12003634/pdf/41467_2025_Article_58551.pdf

[21] ORCA calculation benchmark. https://www.thepromptindex.com/real-world-calculations-in-ai-how-well-do-today-s-language-models-compute-like-a-real-calculator.html

[22] 臺灣登山申請一站式服務網，歷史消息。https://hike.taiwan.gov.tw/news_0_HIS.aspx?Page=2

[23] 中央氣象署 F-B0053-041。https://opendata.cwa.gov.tw/dataset/forecast/F-B0053-041

[24] 中央社（2025-08-21）。玉山東峰雷擊。https://www.cna.com.tw/news/asoc/202508210087.aspx

[25] Firth, P. G. et al. (2008). Mortality on Mount Everest. BMJ. https://pmc.ncbi.nlm.nih.gov/articles/PMC2602730/

[26] 經濟日報（2026）。AI 基本法施行後的產業治理。https://money.udn.com/money/story/11799/9866191

[27] 內政部（2025）。山域事故類型以迷路最多。https://www.moi.gov.tw/News_Content.aspx?n=4&s=325662

[28] 中央社（2026-05-21）。114 年山難獲救率破 93%。https://www.cna.com.tw/news/ahel/202605210315.aspx

[29] 國科會，高風險 AI 框架。https://www.nstc.gov.tw/folksonomy/detail/ed981806-1852-4b63-8dfd-9eea04157971?l=ch
[30] MeasuringU. Interpret a SUS Score. https://measuringu.com/interpret-sus-score/
[31] ai.info. AI chatbot hiking advice and backcountry rescues. https://ai.info/news/ai-chatbot-hiking-advice-backcountry-rescues
[32] 臺灣登山申請一站式服務網，步道分級。https://hike.taiwan.gov.tw/information_6.aspx